

## PERBANDINGAN METODE LOGISTIC REGRESSION DAN RANDOM FOREST DALAM KLASIFIKASI PENYAKIT KULIT MULTIKELAS

<sup>1)</sup> Syatriani, <sup>2)</sup> Rozzi Kesuma Dinata, <sup>3)</sup> Ar Razi

<sup>1,2,3)</sup> Teknik Informatika, Fakultas Teknik, Universitas Malikussalaeh

<sup>1,2,3)</sup> Jl. Batam. Kampus Bukit Indah, Lhokseumawe – Aceh - Indonesia

E-mail: [syatriani.210170231.mhs.unimal.ac.id](mailto:syatriani.210170231.mhs.unimal.ac.id), [rozzi@unimal.ac.id](mailto:rozzi@unimal.ac.id), [ar.razi@unimal.ac.id](mailto:ar.razi@unimal.ac.id)

### ABSTRAK

Penelitian ini membandingkan dua algoritma klasifikasi, yaitu *Logistic Regression* dan *Random Forest*, dalam mengklasifikasikan delapan jenis penyakit kulit berdasarkan sepuluh gejala klinis. Data yang digunakan terdiri dari 271 rekam medis pasien dari RSU Cut Meutia, yang dibagi menjadi 80% data latih dan 20% data uji. Proses pra-pemrosesan mencakup imputasi data kosong, encoding variabel kategorikal, serta normalisasi pada fitur numerik untuk model *Logistic Regression*. Kedua algoritma diimplementasikan menggunakan pustaka Scikit-learn dalam bahasa pemrograman Python. Evaluasi dilakukan menggunakan metrik akurasi, precision, recall, dan F1-score. Hasil menunjukkan bahwa *Logistic Regression* menghasilkan akurasi sebesar 94,55%, sedikit lebih tinggi dibandingkan *Random Forest* yang mencapai 92,73%. Validasi menggunakan 5-fold cross-validation dan uji *paired t-test* menghasilkan nilai p-value 0,0371, yang menunjukkan bahwa perbedaan performa kedua model signifikan secara statistik. Kendati demikian, keterbatasan seperti jumlah data yang relatif kecil dan ketidakseimbangan antar kelas berdampak pada rendahnya performa model pada kategori minoritas seperti Psoriasis. Penelitian ini diharapkan dapat menjadi landasan dalam pengembangan sistem bantu diagnosis medis berbasis data untuk meningkatkan efisiensi dan ketepatan dalam pelayanan kesehatan.

**Kata Kunci:** Klasifikasi, Penyakit Kulit, Logistic Regression, Random Forest, Evaluasi Model

### ABSTRACT

*This study compares two classification algorithms, namely Logistic Regression and Random Forest, in classifying eight types of skin diseases based on ten clinical symptoms. The data used consists of 271 patient medical records from Cut Meutia General Hospital, which are divided into 80% training data and 20% test data. The pre-processing stage included imputing missing data, encoding categorical variables, and normalizing numerical features for the Logistic Regression model. Both algorithms were implemented using the Scikit-learn library in the Python programming language. Evaluation was conducted using accuracy, precision, recall, and F1-score metrics. The results show that Logistic Regression achieved an accuracy of 94.55%, slightly higher than Random Forest, which reached 92.73%. Validation using 5-fold cross-validation and a paired t-test yielded a p-value of 0.0371, indicating that the performance difference between the two models is statistically significant. However, limitations such as the relatively small amount of data and class imbalance impacted the low performance of the model in minority categories such as Psoriasis. This study is expected to serve as a foundation for the development of data-based medical diagnosis assistance systems to improve efficiency and accuracy in healthcare services.*

**Keyword:** Classification, Skin Disease, Logistic Regression, Random Forest, Model Evaluation

### PENDAHULUAN

Sebagai organ terluar tubuh, kulit memiliki fungsi vital dalam menerima rangsangan seperti sentuhan, rasa nyeri, dan berbagai pengaruh dari luar [1]. Kondisi kulit setiap orang berbeda-beda, tergantung pada jenis kulit masing-masing. Berbagai faktor dapat memengaruhi kesehatan kulit hingga berisiko menimbulkan penyakit, antara lain tingkat kebersihan, pola makan, kondisi fisik, paparan bahan kimia, sistem imun, dan faktor

lingkungan.[2]. Di negara beriklim tropis seperti Indonesia, penyakit kulit menjadi salah satu kategori penyakit yang paling kerap ditemui. Berdasarkan Profil kesehatan Indonesia tahun 2023, penyakit kulit termasuk dalam kelompok penyakit dengan tingkat rawat jalan yang tinggi di berbagai fasilitas layanan Kesehatan[3]. Rumah Sakit Umum Cut Meutia adalah salah satu rumah sakit rujukan terbesar di wilayah Lhokseumawe dan Aceh Utara yang menangani berbagai jenis kasus penyakit, termasuk penyakit kulit. Data rekam medis

pasien di rumah sakit ini, yang mencakup informasi gejala, diagnosis, hingga riwayat pengobatan, memiliki potensi besar untuk dianalisis guna mengidentifikasi pola penyakit yang sering terjadi. Namun, keterbatasan waktu dan sumber daya manusia menjadi kendala dalam melakukan analisis secara manual terhadap data dalam jumlah besar. Perkembangan kecerdasan buatan dan data mining telah menghadirkan metode komputasional yang efektif untuk mendukung analisis otomatis terhadap data medis. Salah satunya adalah teknik klasifikasi [4]. Klasifikasi merupakan suatu proses dalam menemukan model atau fungsi yang dapat menggambarkan atau membedakan suatu konsep atau kategori data, dengan tujuan untuk memprediksi kelas dari suatu objek yang belum diketahui labelnya yang bertujuan mengelompokkan data berdasarkan karakteristik tertentu [5]. Dalam konteks medis, klasifikasi berperan penting dalam membantu proses diagnosis penyakit berdasarkan data gejala yang dimiliki pasien. Sejumlah penelitian sebelumnya telah mengembangkan sistem klasifikasi penyakit kulit berbasis citra digital. Furqan, Nasution, dan Fadillah (2022) menggunakan algoritma Naïve Bayes dengan fitur tekstur dan warna citra, serta preprocessing berupa grayscale dan thresholding. Sistem ini mampu mengenali lima jenis penyakit kulit dengan akurasi mencapai 75% [1]. Selanjutnya, penelitian yang dilakukan oleh Muhammad Atsil Hanin, Raditiana Patmasari, dan R. Yunendah Nur Fu'adah memanfaatkan metode Convolutional Neural Network (CNN) untuk membangun sistem klasifikasi penyakit kulit berbasis citra digital. Sistem ini mampu memproses citra kulit beresolusi tinggi dan mengenali pola-pola visual yang berkaitan dengan penyakit seperti cacar air (varicella) dan campak. Evaluasi dilakukan menggunakan metrik seperti precision, recall, dan F1-score untuk mengukur

performa sistem secara menyeluruh. Hasil pengujian menunjukkan bahwa sistem CNN yang dikembangkan berhasil mencapai akurasi tinggi sebesar 96,53% dengan nilai loss yang rendah, yaitu 0,2486, menunjukkan kinerja yang optimal dalam klasifikasi penyakit kulit [6]. Penelitian yang relevan juga dilakukan oleh Supirman, Lubis, Yulianto, dan Perdana (2023) membandingkan dua arsitektur *Convolutional Neural Network* (CNN), yaitu VGG16 dan MobileNet, dalam melakukan klasifikasi citra penyakit kulit. Proses pelatihan dilakukan hingga 100 *epoch*, dengan hasil menunjukkan bahwa arsitektur VGG16 memiliki performa yang lebih baik dibandingkan MobileNet. Akurasi tertinggi dicapai oleh VGG16, yaitu sebesar 86,61%, MobileNet menunjukkan akurasi yang lebih rendah, yaitu 80% saat pelatihan dan 82% pada evaluasi [7]. Sebagian besar penelitian klasifikasi penyakit kulit sebelumnya menggunakan pendekatan berbasis citra digital, pendekatan lain yang juga potensial adalah klasifikasi berdasarkan data gejala klinis yang bersifat tekstual atau numerik. Dalam konteks ini, algoritma Logistic Regression dan Random Forest telah banyak digunakan pada berbagai jenis penyakit dan terbukti mampu menghasilkan performa klasifikasi yang baik. Seperti penelitian yang berjudul Implementasi Logistic Regression untuk Klasifikasi Penyakit Stroke, hasil menunjukkan bahwa Algoritma Logistic Regression menunjukkan performa yang unggul dalam klasifikasi penyakit stroke, dengan akurasi mencapai 94%. Selain itu, model ini juga mencatat tingkat ketepatan sebesar 94%, tingkat recall sebesar 100%, dan skor F1 sebesar 97%, yang mencerminkan keseimbangan performa antara presisi dan sensitivitas [8]. Sementara itu, penelitian yang berjudul Prediksi Kemungkinan Diabetes pada Tahap Awal Menggunakan Algoritma Klasifikasi Random Forest menunjukkan

bahwa algoritma Random Forest memberikan hasil yang sangat baik dalam klasifikasi penyakit diabetes, dengan akurasi sebesar 97,88%, precision dan recall masing-masing sebesar 0,979, serta nilai ROC sebesar 0,998 [9]. Hasil-hasil tersebut menunjukkan bahwa performa algoritma klasifikasi dapat bervariasi tergantung pada jenis penyakit dan karakteristik data. Namun, belum banyak studi yang secara langsung membandingkan Logistic Regression dan Random Forest dalam klasifikasi penyakit kulit multikelas berbasis data gejala klinis di rumah sakit. Sebagian besar penelitian masih berfokus pada citra medis atau penyakit yang lain, sementara pemanfaatan data tekstual dari rekam medis relatif jarang diteliti. Penelitian ini bertujuan untuk mengisi celah tersebut dan memberikan kontribusi dalam pengembangan sistem klasifikasi penyakit kulit yang sederhana, efisien, dan dapat diterapkan di fasilitas layanan kesehatan.

## METODE

Untuk mencapai tujuan penelitian, proses klasifikasi dilakukan melalui enam tahapan utama yang meliputi identifikasi masalah hingga evaluasi kinerja model. Rincian tahapan tersebut disajikan sebagai berikut:

### 1. Identifikasi Masalah

Di langkah ini, penulis mengamati dan merumuskan permasalahan terkait pentingnya klasifikasi penyakit kulit guna membantu proses diagnosis yang lebih cepat dan akurat. Permasalahan difokuskan pada bagaimana algoritma machine learning dapat dimanfaatkan untuk mengklasifikasikan berbagai penyakit kulit yang berbeda berdasarkan data pasien.

### 2. Pengumpulan Data

Data dikumpulkan dari rekam medis pasien di Rumah Sakit Umum Cut Meutia. Dataset terdiri dari 271 data pasien, dengan 10 fitur gejala yang digunakan sebagai

variabel input. Kelas target terdiri dari 8 jenis penyakit kulit yang berbeda.

### 3. Pra-pemrosesan Data

Data gejala dikonversi menjadi format numerik biner (1 = gejala muncul, 0 = tidak muncul). Data selanjutnya dipisahkan menjadi dua subset, dengan 80% digunakan sebagai data latih dan 20% sebagai data uji, agar proses pelatihan dan pengujian model dapat berjalan optimal.

### 4. Pemilihan Algoritma

Penelitian ini menggunakan dua algoritma klasifikasi, yaitu Logistic Regression dan Random Forest. Logistic Regression dipilih karena efisien secara komputasi dan cocok untuk klasifikasi multikelas berbasis data gejala. Sementara itu, Random Forest digunakan karena kemampuannya menangani kompleksitas data dan mengurangi overfitting. Kedua model diimplementasikan menggunakan pustaka Scikit-learn dengan parameter utama seperti yang ditampilkan pada Tabel 1 dan Tabel 2. Penelitian ini menggunakan konfigurasi parameter dasar (default) dari pustaka tersebut, tanpa melakukan optimasi hyperparameter lanjutan seperti grid search atau validasi silang. Hal ini dilakukan untuk menilai performa awal masing-masing algoritma secara langsung tanpa pengaruh tuning tambahan. Pemilihan pustaka Scikit-learn didasarkan pada efisiensi, kemudahan penggunaan, dokumentasi yang lengkap, serta dukungan terhadap berbagai algoritma dan fungsi evaluasi. Scikit-learn juga telah menjadi pustaka standar yang banyak digunakan dalam penelitian klasifikasi berbasis machine learning, sehingga dianggap tepat untuk membangun baseline model dalam studi ini.

Tabel 1. Parameter Logistic Regression

No	Parameter	Nilai
1	penalty	"l2"
2	C	1.0
3	solver	"lbfgs"
4	multi_class	"auto"

5	max_iter	1000
---	----------	------

Tabel 2. Parameter Random Forest

No	Parameter	Nilai
1	n_estimators	100
2	criterion	"gini"
3	max_depth	None
4	max_features	"sqrt"
5	bootstrap	True
6	random_state	42

### 5. Pelatihan dan Pengujian Model

Model dilatih menggunakan pustaka Scikit-learn dalam lingkungan Jupyter Notebook berbasis Python. Parameter default digunakan untuk Logistic Regression, sementara Random Forest menggunakan 100 pohon keputusan. Model diuji menggunakan data uji untuk mengukur performa klasifikasi.

### 6. Evaluasi Kinerja

Proses evaluasi dilakukan dengan menghitung metrik akurasi, precision, recall, dan F1-score. Keempat metrik tersebut digunakan untuk mengukur performa model dalam melakukan klasifikasi penyakit kulit secara tepat.

## Logistic Regression

Logistic Regression adalah algoritma klasifikasi yang umum digunakan dalam machine learning, khususnya untuk memprediksi variabel target dengan tipe kategori [10]. Dalam ranah data mining, Logistic Regression digunakan sebagai metode untuk mengevaluasi hubungan antara variabel target (dependen) dengan satu atau lebih variabel input (independen). Metode ini khusus diterapkan ketika variabel target (respon) berskala kategorikal atau nominal, baik dalam bentuk dua kategori (biner) maupun lebih.

Logistic Regression dirancang sedemikian rupa untuk menghasilkan prediksi dalam rentang probabilitas antara 0 dan 1, sehingga hasil klasifikasi selalu berada dalam batas logis tersebut.[11]. Untuk menyelesaikan masalah klasifikasi multikelas, digunakan pendekatan One-vs-Rest (OvR), yaitu dengan membuat satu model logistic regression untuk setiap kelas. Pada masing-masing model, satu kelas diperlakukan sebagai kelas positif (1), dan semua kelas lainnya sebagai negatif (0). Persamaan berikut menunjukkan bentuk umum model Logistic Regression yang digunakan pada pendekatan One-vs-Rest (OvR) untuk klasifikasi multikelas

$$P(y = k|\mathbf{X}) = \frac{1}{1 + e^{-z_k}}$$

$$z_k = \beta_0^{(k)} + \beta_1^{(k)}X_1 + \beta_2^{(k)}X_2 + \dots + \beta_n^{(k)}X_n$$

Keterangan

$P(y = k|\mathbf{X})$  : Probabilitas data termasuk ke kelas- $k$

$X_1, X_2, \dots, X_n$  : Fitur (variabel input)

$\beta_0^{(k)}$  : Intersep (bias) untuk kelas ke- $k$

$\beta_1^{(k)}, \beta_2^{(k)}, \dots, \beta_n^{(k)}$  : Koefisien (bobot) fitur untuk kelas ke- $k$

Fungsi sigmoid  $\frac{1}{1+e^{-z}}$  digunakan untuk mengubah nilai  $z_k$  menjadi probabilitas antara 0 dan 1.

## Random Forest

Random Forest merupakan algoritma machine learning berbasis ensemble learning yang bekerja dengan mengompilasi hasil prediksi dari sejumlah pohon keputusan untuk memperoleh hasil akhir yang lebih stabil dan andal. Pendekatan ini bertujuan untuk meningkatkan akurasi model serta meminimalkan kemungkinan terjadinya overfitting melalui proses voting atau rata-rata dari hasil masing-masing pohon. [12]. Random Forest memiliki beberapa kelebihan, termasuk

kemampuan untuk meningkatkan akurasi dalam kasus data yang hilang dan mencegah kesalahan, serta kemampuan untuk menyimpan data dengan efisien.[13]. Algoritma metode Random Forest yaitu :

1. Menggunakan metode bootstrap resampling dengan pengembalian untuk mendapatkan  $n$  data sampel dari dataset awal.
2. Pohon klasifikasi dibentuk melalui proses *bootstrap resampling* pada masing-masing dataset, kemudian pemilihan pengklasifikasi terbaik dilakukan dengan mengambil atribut secara acak. Banyaknya atribut acak tersebut dapat dihitung menggunakan rumus  $\frac{1}{2}\sqrt{m}, \sqrt{m}, 2\sqrt{m}$  di mana  $m$  merupakan total variabel prediktor yang tersedia.
3. Setiap data sampel diklasifikasikan berdasarkan hasil dari pohon klasifikasi yang telah disusun
4. Prosedur pada langkah pertama hingga ketiga diulangi hingga tercapai jumlah pohon klasifikasi yang ditetapkan, dan seluruh proses tersebut diulang sebanyak  $k$  kali.
5. Prediksi yang dihasilkan dari semua pohon klasifikasi kemudian digabungkan untuk menetapkan hasil klasifikasi akhir pada data sampel.

Nilai  $m$  Algoritma Random Forest bervariasi. Dalam proses pembentukan pohon klasifikasi, nilai  $m$  adalah jumlah variabel prediktor yang digunakan sebagai pemisah. Nilai  $m$  yang lebih tinggi akan menghasilkan korelasi yang lebih tinggi.[14].

#### Dataset

Seluruh data yang digunakan dalam studi ini bersumber dari dokumentasi rekam medis pasien di Rumah Sakit Umum Cut Meutia, yang merupakan rumah sakit rujukan di wilayah Lhokseumawe dan sekitarnya. Dataset

mencakup informasi medis dari 271 pasien yang telah didiagnosis menderita salah satu dari delapan jenis penyakit kulit. Setiap data pasien terdiri dari sepuluh fitur gejala klinis. Dataset juga memuat informasi demografis dasar berupa jenis kelamin dan usia pasien. Distribusi jenis kelamin dalam dataset tergolong seimbang, dengan 50,18% pasien laki-laki dan 49,82% perempuan, sebagaimana ditunjukkan pada Tabel 3. Dari sisi usia, mayoritas pasien berada dalam rentang usia produktif (20–60 tahun), dengan kelompok usia 41–60 tahun sebagai yang terbanyak, seperti terlihat pada Tabel 4.

Tabel 3. Distribusi Jenis Kelamin

Jenis Kelamin	Jumlah Pasien	Persentase (%)
Laki-laki	136	50.18%
Perempuan	135	49.82%

Tabel 4. Distribusi Usia

Kelompok Usia	Jumlah Pasien	Persentase (%)
< 20 tahun	38	14.18%
20–40 tahun	70	26.12%
41–60 tahun	89	33.21%
> 60 tahun	71	26.49%

Tabel 5. Distribusi Penyakit

Jenis Penyakit	Jumlah Pasien	Persentase (%)
Abses	138	50.92%
Dermatitis	62	22.88%
Selulitis	25	9.23%
Ulkus	21	7.75%
Dekubitus		
Pemfigus	9	3.32%
Vulgaris		
Urtikaria	6	2.21%
Impetigo	6	2.21%
Psoriasis	4	1.48%

Tabel 6. Atribut Dataset

No	Fitur	Tipe Data	Keterangan
1	Bengkak	Y/N	Apakah mengalami pembengkakan
2	Kemerahan	Y/N	Apakah kulit tampak memerah
3	Nyeri	Y/N	Apakah merasakan nyeri
4	Bernanah	Y/N	Apakah luka mengeluarkan nanah
5	Luka Terbuka	Y/N	Apakah terdapat luka terbuka
6	Gatal	Y/N	Apakah merasakan gatal
7	Kulit Bersisik	Y/N	Apakah kulit tampak bersisik
8	Lepuh	Y/N	Apakah muncul lepuhan berisi cairan
9	Demam	Y/N	Apakah pasien mengalami demam
10	Ruam	Y/N	Apakah muncul ruam kemerahan di kulit
11	Penyakit Kulit	Multikelas	Kelas Target

Tabel 7. Kelas Target

Abses
Dermatitis
Selulitis
Psoriasis
Urtikaria
Impetigo
Pemvigus Vulgaris
Ulkus Dekubitus

### Pra-pemrosesan Data

Pra-pemrosesan data merupakan tahap krusial dalam siklus kerja data mining karena secara langsung memengaruhi kualitas model dan hasil klasifikasi. Tahapan ini dilakukan untuk mentransformasikan data mentah menjadi data yang telah dibersihkan,

distandarkan, dan siap digunakan oleh algoritma machine learning. [15]. Dalam penelitian ini, beberapa langkah utama dilakukan untuk memastikan integritas dan keterbacaan data yaitu,

1. Tahapan awal yang dilaksanakan adalah pembersihan data (data cleaning). Di fase ini, data diperiksa untuk mengetahui adanya data duplikat dan data kosong (missing value). Data duplikat dihapus agar tidak mempengaruhi distribusi kelas yang akan dipelajari oleh model. Sementara itu, untuk menangani data kosong pada kolom gejala, digunakan pendekatan pengisian dengan nilai 0, yang mengindikasikan bahwa gejala tersebut tidak dialami oleh pasien. Hal ini dilakukan agar jumlah data tetap utuh dan tidak kehilangan informasi penting lainnya
2. Tahap berikutnya adalah pengkodean label atau klasifikasi penyakit kulit. Karena algoritma klasifikasi memerlukan data numerik, maka label diagnosis penyakit yang awalnya berupa teks seperti “Abses”, “Dermatitis”, atau “Psoriasis” dikonversi ke dalam bentuk numerik dengan menggunakan teknik *label encoding*. Misalnya, “Abses” diubah menjadi 0, “Selulitis” menjadi 1, dan seterusnya hingga semua jenis penyakit kulit yang digunakan sebagai kelas target (class label) diberi representasi numerik.
3. Selanjutnya, dilakukan transformasi pada fitur gejala menjadi bentuk numerik biner. Setiap gejala seperti bengkak, nyeri, atau luka dikodekan dengan nilai 1 jika gejala tersebut dialami oleh pasien, dan 0 jika tidak. Dengan cara ini, seluruh fitur yang digunakan dalam model klasifikasi berada dalam format numerik yang dapat diterima oleh algoritma Logistic Regression maupun Random Forest.

4. Tahapan opsional berikutnya adalah normalisasi atau standarisasi data, terutama untuk mendukung performa Logistic Regression yang sensitif terhadap skala data. Normalisasi dilakukan menggunakan metode *Standard Scaler* agar semua fitur memiliki distribusi dengan rata-rata 0 dan standar deviasi 1.
5. Pada tahap akhir, dataset dipisahkan menjadi data latih dan data uji dengan rasio pembagian 80:20 untuk keperluan pelatihan dan pengujian model. Hal ini berarti bahwa 80% dari keseluruhan data dialokasikan untuk proses pelatihan model, dan 20% sisanya digunakan untuk menguji seberapa baik model bekerja. Pemisahan tersebut menjadi aspek penting agar evaluasi dapat mencerminkan kemampuan algoritma dalam menghadapi data baru yang belum pernah dikenali sebelumnya.

### Evaluasi Model

Tahapan evaluasi ini menggunakan metode confusion matrix sebagai alat ukur kinerja model klasifikasi. Pendekatan ini memungkinkan penilaian terhadap akurasi model dalam mengklasifikasikan data ke dalam kelas yang benar, serta memberikan gambaran mengenai bentuk dan frekuensi kesalahan prediksi yang terjadi.[16].

### HASIL

Tujuan dari studi ini adalah mengevaluasi dan membandingkan kinerja algoritma Logistic Regression dan Random Forest dalam melakukan klasifikasi terhadap delapan kategori penyakit kulit berdasarkan sepuluh indikator gejala klinis pasien. Sebanyak 272 data pasien digunakan dalam dataset, yang kemudian dibagi menjadi 80% data latih dan 20% data uji. Kinerja model dievaluasi melalui metrik evaluasi seperti akurasi, precision, recall, dan f1-score.

Berdasarkan hasil pengujian, model Logistic Regression memberikan akurasi sebesar 94.55%, sementara Random Forest memperoleh akurasi sebesar 92.73%. Perbandingan metrik evaluasi dari kedua model ditunjukkan pada tabel 8.

Tabel 8. Evaluasi Model

Model	Akurasi	Presisi	Recal	F-1 Score
Logistic Regression	94.55%	94%	95%	95%
Random Forest	92.73%	93%	93%	93%

Nilai-nilai ini menunjukkan bahwa model Logistic Regression memberikan hasil klasifikasi yang sedikit lebih unggul dibandingkan Random Forest. Secara khusus, Logistic Regression menunjukkan konsistensi yang lebih baik dalam menjaga keseimbangan antara presisi dan sensitivitas, yang tercermin dari nilai F1-score yang lebih tinggi. Detail dari metrik evaluasi masing-masing kelas penyakit ditampilkan pada tabel di bawah.

Tabel 9. Metrik Evaluasi Logistic Regression

Penyakit	Precision	Recall	F1-score
Abses	0.97	1.00	0.98
Dermatitis	0.92	0.92	0.92
Impetigo	1.00	1.00	1.00
Pemfigus	1.00	1.00	1.00
Vulgaris			
Psoriasis	0.00	0.00	0.00
Selulitis	1.00	0.80	0.89
Ulkus	1.00	1.00	1.00
Dekubitus			
Urtikaria	0.50	1.00	0.67

Evaluasi terhadap model Logistic Regression menunjukkan bahwa model ini mampu memberikan kinerja yang cukup memuaskan pada mayoritas kelas yang

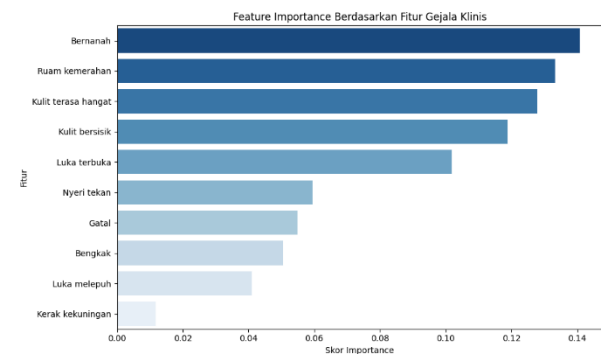
diklasifikasikan. Kelas Abses, Impetigo, dan Ulkus Dekubitus memperoleh nilai precision, recall, dan f1-score yang sangat tinggi, bahkan mendekati atau mencapai 1.00. Hal ini menunjukkan bahwa model mampu mengenali dan memprediksi kasus pada kelas-kelas tersebut dengan sangat akurat dan konsisten. Namun demikian, kelemahan model ini terlihat jelas pada kelas Psoriasis, di mana precision, recall, dan f1-score semuanya 0.00. Ini menandakan bahwa tidak ada satupun data uji yang berhasil diprediksi dengan benar untuk kelas tersebut, kemungkinan karena data yang sangat sedikit. Kelas Pemfigus Vulgaris dan Urtikaria juga menunjukkan nilai f1-score di bawah 0.80, yang mengindikasikan adanya ketidakseimbangan antara presisi dan sensitivitas.

Tabel 10. Metrik Evaluasi Random Forest

Penyakit	Precision	Recall	F1-score
Abses	0.97	1.00	0.98
Dermatitis	0.92	0.85	0.88
Impetigo	1.00	1.00	1.00
Pemfigus Vulgaris	1.00	1.00	1.00
Psoriasis	0.00	0.00	0.00
Selulitis	1.00	0.80	0.89
Ulkus Dekubitus	1.00	1.00	1.00
Urtikaria	0.50	1.00	0.67

Model Random Forest juga menunjukkan performa yang baik, khususnya pada kelas Abses, Impetigo, dan Ulkus Dekubitus, dengan precision dan recall bernilai 1.00. Temuan ini mengindikasikan bahwa model memiliki efektivitas tinggi dalam mengenali kasus pada kelas-kelas tersebut. Nilai f1-score pada kelas-kelas ini juga sempurna. Namun, seperti halnya pada Logistic Regression, model Random Forest juga


mengalami kesulitan dalam memprediksi kelas Psoriasis, yang memiliki precision, recall, dan f1-score 0.00. Kelas Urtikaria juga menunjukkan precision hanya 0.50, menandakan bahwa model sering salah dalam mengklasifikasikan prediksi untuk kelas tersebut. Sementara recall-nya cukup tinggi yaitu 1.00, ini berarti model terlalu sering menganggap data sebagai Urtikaria, padahal belum tentu benar (false positive tinggi).




Gambar 1. Feature Importance Random Forest

Gambar di atas memperlihatkan hasil analisis feature importance berdasarkan algoritma Random Forest, yang difokuskan hanya pada fitur-fitur berbasis gejala klinis. Fitur bernanah, ruam kemerahan, dan kulit terasa hangat merupakan yang paling berkontribusi dalam klasifikasi penyakit kulit. Sebaliknya, fitur seperti kerak kekuningan dan luka melepuh memiliki skor penting yang lebih rendah. Temuan ini dapat menjadi acuan dalam pengembangan sistem klasifikasi berbasis data klinis yang lebih efisien.





Gambar 2. Confusion Matrix Logistic Regression




Gambar 3. Confusion Matrix Random Forest

Analisis confusion matrix pada kedua model mengindikasikan bahwa keduanya mampu mengklasifikasikan sebagian besar jenis penyakit kulit dengan cukup baik. Model Logistic Regression secara konsisten mampu memprediksi mayoritas kelas dengan benar, terutama pada kelas Abses dan Pemfigus Vulgaris, dengan kesalahan klasifikasi yang rendah. Random Forest juga menunjukkan performa memuaskan pada kelas-kelas dominan, namun mengalami penurunan akurasi pada kelas Dermatitis dan Psoriasis, yang kemungkinan disebabkan oleh kemiripan gejala antar kelas dan jumlah data yang tidak seimbang. Khusus untuk kelas Psoriasis, kedua model gagal mengklasifikasikan kasus dengan benar, yang ditunjukkan oleh nilai precision, recall, dan F1-score sebesar 0.00. Hal ini diduga karena jumlah data Psoriasis yang sangat kecil, sehingga model tidak mampu mempelajari pola

representatif dari kelas tersebut. Selain itu, performa rendah juga terlihat pada kelas Urtikaria, dengan nilai precision hanya 0.50, yang menunjukkan tingginya jumlah false positive. Kondisi ini bisa berdampak serius dalam konteks aplikasi medis, karena dapat menyebabkan salah diagnosis.

Penelitian ini belum menerapkan metode penanganan ketidakseimbangan data, seperti SMOTE, pembobotan kelas, atau undersampling. Oleh karena itu, untuk pengembangan selanjutnya, sangat disarankan agar metode tersebut diterapkan guna meningkatkan akurasi dan stabilitas model, terutama pada kelas-kelas minoritas.



Gambar 4. Visualisasi Perbandingan akurasi

Perbandingan akurasi kedua model secara visual menggunakan grafik batang. Terlihat bahwa Logistic Regression mencapai akurasi sebesar 94,55%, sedikit lebih tinggi dibandingkan Random Forest yang memperoleh akurasi 92,73%. Perbedaan ini menunjukkan bahwa Logistic Regression lebih konsisten dalam memetakan gejala terhadap jenis penyakit kulit yang sesuai.

### Validasi Model

Untuk memastikan kestabilan hasil klasifikasi, dilakukan evaluasi tambahan menggunakan 5-fold cross-validation. Tabel 11 menunjukkan akurasi masing-masing fold untuk kedua model. Rata-rata akurasi Logistic Regression adalah 94,86%, lebih tinggi

dibandingkan Random Forest yang hanya mencapai 91,96%. Selanjutnya, dilakukan uji paired t-test terhadap hasil akurasi tersebut. Nilai *p-value* yang diperoleh adalah 0.0371, yang berarti perbedaan performa kedua model signifikan secara statistik ( $p < 0.05$ ). Hal ini memperkuat kesimpulan bahwa Logistic Regression memiliki keunggulan yang dapat dibuktikan secara statistik.

Tabel 11. Hasil Cross-Validation

Fold ke-	Logistic Regression	Random Forest
1	92.73%	90.91%
2	96.30%	92.59%
3	92.59%	92.59%
4	96.30%	90.74%
5	96.30%	90.74%
Rata-rata	94.86%	91.96%

## KESIMPULAN

Tujuan dari penelitian ini adalah untuk menilai sejauh mana algoritma Logistic Regression dan Random Forest mampu mengklasifikasikan delapan kategori penyakit kulit berdasarkan sepuluh gejala klinis pasien. Data yang digunakan bersumber dari rekam medis pasien di RSUD Cut Meutia. Hasil pengujian menunjukkan bahwa Logistic Regression memberikan hasil akurasi sebesar 94,55%, sedangkan Random Forest memperoleh akurasi 92,73%. Selain akurasi, evaluasi menggunakan precision, recall, dan F1-score juga menunjukkan bahwa Logistic Regression memiliki performa yang lebih stabil dalam konteks klasifikasi multikelas.

Berdasarkan hasil tersebut, dapat disimpulkan bahwa Logistic Regression lebih unggul dibandingkan Random Forest pada dataset ini. Hasil ini berpotensi digunakan

sebagai dasar pengembangan sistem bantu diagnosis berbasis data, yang dapat diterapkan di rumah sakit atau fasilitas layanan kesehatan untuk membantu proses identifikasi awal penyakit kulit secara lebih cepat dan akurat.

Untuk pengembangan lebih lanjut, penelitian dapat diarahkan pada integrasi pendekatan multimodal, seperti menggabungkan data gejala klinis dengan data citra kulit. Dengan demikian, model klasifikasi dapat mempertimbangkan informasi visual maupun non-visual secara bersamaan, yang berpotensi meningkatkan akurasi dan ketepatan diagnosis. Selain itu, strategi penanganan ketidakseimbangan data, seperti penggunaan SMOTE, pembobotan kelas, atau validasi silang lebih dalam, juga disarankan guna meningkatkan performa klasifikasi pada kelas penyakit dengan jumlah data yang sedikit.

## DAFTAR PUSTAKA

- [1] M. Furqan, Y. R. Nasution, and R. Fadillah, "Klasifikasi Penyakit Kulit Menggunakan Algoritma Naïve Bayes Berdasarkan Tekstur Warna Berbasis Android," *J. Sains Komput. Inform.*, vol. 6, no. 1, pp. 12–20, 2022.
- [2] D. A. Wijaya, A. Triayudi, and A. Gunawan, "Penerapan Artificial Intelligence Untuk Klasifikasi Penyakit Kulit Dengan Metode Convolutional Neural Network Berbasis Web," *J. Comput. Syst. Informatics*, vol. 4, no. 3, pp. 685–692, 2023, doi: 10.47065/josyc.v4i3.3519.
- [3] Rizky Adawiyah and Dadang Iskandar Mulyana, "Optimasi Deteksi Penyakit Kulit Menggunakan Metode Support Vector Machine (SVM) dan Gray Level Co-occurrence Matrix (GLCM)," *Inf. (Jurnal Inform. dan Sist. Informasi)*, vol. 14, no. 1, pp. 18–33, 2022, doi: 10.37424/informasi.v14i1.138.
- [4] S. Terlaris, D. Algoritma, A. L. Dasiva, A. A. Briantoro, and B. O. Lubis, "PENERAPAN DATA MINING

- UNTUK KLASIFIKASI DATA PENJUALAN,” vol. 9, no. 3, pp. 4616–4621, 2025.
- [5] J. J. Aripin, “Penerapan Algoritma Naive Bayes Untuk Mengklasifikasi Data Nasabah Asuransi pada BPR Pantura,” *TECHSI J. Penelit. Tek. Inform.*, 2019.
- [6] M. A. Hanin, R. Patmasari, and R. Y. Nur, “Sistem Klasifikasi Penyakit Kulit Menggunakan Convolutional Neural Network ( Cnn ) Skin Disease Classification System Using Convolutional Neural Network ( Cnn ),” *e-Proceeding Eng.*, vol. 8, no. 1, pp. 273–281, 2021.
- [7] S. Supirman, C. Lubis, D. Yulianto, and N. J. Perdana, “Klasifikasi Penyakit Kulit Menggunakan Convolutional Neural Network (Cnn) Dengan Arsitektur Vgg16,” *Simtek J. Sist. Inf. dan Tek. Komput.*, vol. 8, no. 1, pp. 135–140, 2023, doi: 10.51876/simtek.v8i1.217.
- [8] H. Hikmayanti Handayani, K. Ahmad Baihaqi, and U. Buana Perjuangan Karawang, “Implementasi Algoritma Logistic Regression Untuk Klasifikasi Penyakit Stroke,” *Syntax J. Inform.*, vol. 12, no. 01, pp. 15–23, 2023.
- [9] W. Apriliah, I. Kurniawan, M. Baydhowi, and T. Haryati, “Prediksi Kemungkinan Diabetes pada Tahap Awal Menggunakan Algoritma Klasifikasi Random Forest,” *Sistemasi*, vol. 10, no. 1, p. 163, 2021, doi: 10.32520/stmsi.v10i1.1129.
- [10] Y. N. Khoiril Umat, D. Rusyda Nafsyi, D. Kusumaningsih, and L. Hakim, “Analisis Faktor Yang Mempengaruhi Pemilihan Gubernur Daerah Khusus Jakarta Menggunakan Algoritma Naive Bayes Dan Regresi Logistik,” *Rabit J. Teknol. dan Sist. Inf. Univrab*, vol. 9, no. 2, pp. 211–224, 2024, doi: 10.36341/rabit.v9i2.4778.
- [11] F. R. Suprihati, “Analisis Klasifikasi SMS Spam Menggunakan Logistic Regression,” *J. Sist. Cerdas*, vol. 4, no. 3, pp. 155–160, 2021, doi: 10.37396/jsc.v4i3.166.
- [12] F. Di and K. Gayo, “Prediksi potensi wisata menggunakan algoritma random forest di kabupaten gayo lues 1) 1,2,3),” vol. 10, no. 2, pp. 741–751, 2025.
- [13] R. Supriyadi, W. Gata, N. Maulidah, and A. Fauzi, “Penerapan Algoritma Random Forest Untuk Menentukan Kualitas Anggur Merah,” *E-Bisnis J. Ilm. Ekon. dan Bisnis*, vol. 13, no. 2, pp. 67–75, 2020, doi: 10.51903/e-bisnis.v13i2.247.
- [14] S. Mahmuda, “Implementasi Metode Random Forest pada Kategori Konten Kanal Youtube,” *J. Jendela Mat.*, vol. 2, no. 01, pp. 21–31, 2024, doi: 10.57008/jjm.v2i01.633.
- [15] M. S. Rohman and T. N. Rahmawati, “Muhammad Syaifur Rohman, 2) Tsalisa Noor Rahmawati 2),” vol. 10, no. 2, pp. 567–575, 2025.
- [16] F. K. Fikriah, A. D. P. Ariyanto, and A. F. Setyawan, “Klasifikasi Hasil Mri Tumor Otak Dengan Ekstraksi Fitur Gray Level Co-Occurance Matrix (GlcM),” *Rabit J. Teknol. dan Sist. Inf. Univrab*, vol. 9, no. 2, pp. 343–350, 2024, doi: 10.36341/rabit.v9i2.4793.